Университет ИТМО Факультет программной инженерии и компьютерной техники

Курс «Искусственный интеллект»

Лабораторная работа № 5

Вариант: 273720

Работу выполнил

Хуан Сыюань Р33101

Преподаватель

Игорь Александрович Бессмертный

Санкт-Петербург 2021

Задание

Цель: решить задачу многоклассовой классификации, используя в качестве тр енировочного набора данных - набор данных MNIST, содержащий образы рук описных цифр.

- 1. Используйте метод главных компонент для набора данных MNIST (train dataset объема 60000). Определите, какое минимальное количество главных к омпонент необходимо использовать, чтобы доля объясненной дисперсии пре вышала 0.80 + номер_в_списке % 10. Построить график зависимости доли объясненной дисперсии от количества используемых ГК
- 2. Выведите количество верно классифицированных объектов класса номер_в _списке % 9 для тестовых данных
- 3. Введите вероятность отнесения 5 любых изображений из тестового набора к назначенному классу
- 4. Определите Accuracy, Precision, Recall и F1 для обученной модели
- 5. Сделайте вывод про обученную модель

Выполнение лабораторной работы


Question 1

Codes:

```
X_train = X_train.reshape(len(X_train), dim)
pca = PCA(n_components=M, svd_solver='full')
pca = pca.fit(X_train)
explained_variance = np.round(np.cumsum(pca.explained_variance_ratio_),3)
plt.plot(np.arange(M), explained_variance, ls = '-')
```


Answers:

The number of Principal Components so that the proportion of the explained variance exceeds 0.8: 44



Dependence of the proportion of the explained variance on all:

[<matplotlib.lines.Line2D at 0x7f4de9c83090>]



Question 2

Codes and answers:

```
[58] from sklearn.multiclass import OneVsRestClassifier
       from sklearn.tree import DecisionTreeClassifier
秒
        from sklearn.ensemble import RandomForestClassifier
        from sklearn.model_selection import train_test_split
        from sklearn.metrics import confusion_matrix
       X_train, X_test, y_train, y_test = train_test_split(X_train, y_train, test_size=0.3, random_state=2020)
       X_train = pca.transform(X_train)
       X_test = pca.transform(X_test)
       modelPCA = pca.fit(X_test)
       X_test = modelPCA.transform(X_test)
       tree = RandomForestClassifier(criterion='gini', min_samples_leaf=10, max_depth=20, n_estimators=10, random_state=2020)
       clf = OneVsRestClassifier(tree).fit(X_train, y_train)
       y_pred = clf.predict(X_test)
       CM = confusion_matrix(y_test, y_pred)
       print("The number of correctly classified objects of the class " + str(classa) + ":"
                   + str(CM[classa][classa]))
   The number of correctly classified objects of the class 3:233
```

Question 3

Codes and answers:

```
pics = [110, 1014, 996, 520, 250]
for pic in pics:
    print(f"Probability of attribution of picture No [pic] to the assigned class (y_pred[pic]) = (clf.predict_proba(X_test)[pic][y_pred[pic]])")

Probability of attribution of picture No 110 to the assigned class 0 = 0.5835864097273735
Probability of attribution of picture No 1014 to the assigned class 7 = 0.5060023600489468
Probability of attribution of picture No 1014 to the assigned class 4 = 0.5978781978474554
Probability of attribution of picture No 10250 to the assigned class 8 = 0.3447542075896968
Probability of attribution of picture No 10250 to the assigned class 0 = 0.5439224893612968
```

Question 4

Codes and answers:

```
from sklearn.metrics import classification_report, accuracy_score target_names = ['class 0', 'class 1', 'class 2','class 3','class 4','class 5','class 6','class 7','class 8','class 9']
 print("Accuracy: ", accuracy_score(y_test, y_pred))
 print(classification_report(y_test, y_pred, target_names = target_names))
Accuracy: 0.6836111111111111
                           recall fl-score support
               precision
      class 0
                    0.89
                               0.86
                                         0.88
      class 1
                    0.94
                               0.81
                                         0.87
                                                    2075
                                                    1763
      class 2
                    0.46
                               0.58
                                         0.51
                     0.70
                               0.79
      class 3
      class 4
                    0.78
                               0.78
                                         0.78
                                                    1756
      class 5
                    0.50
                               0.45
                                         0.48
                                                    1591
                               0.37
                    0.44
                                                    1766
                                         0.40
      class 6
                    0.75
                               0.78
      class 7
      class 8
                    0.64
                               0.64
                                         0.64
                                                    1773
      class 9
                    0.72
                               0.71
                                         0.71
                                                    1824
                                         0.68
                                                   18000
    macro avg
                    0.68
                               0.68
                                         0.68
                                                   18000
                    0.69
                                         0.68
                                                   18000
 weighted avg
                               0.68
```

Вывод

As a result of the laboratory work, a model was trained to predict the drawn numbers on the MNIST set using 44 principal components out of 784 available, resulting in a share of explained variance of 0.8 on the test sample. The resulting model has a precision of 0.684 and does a good job of determining the digits 0, 1, 3, 4, 7, and 9 in comparison to the rest of the digits, for which the more informative measures Precision, Recall, and F1 are much lower and less than 0.5.